

こころ将棋 AI

— 駒をエージェントとする将棋 AI について —

ものづくりサークル

概要

本報告は、盤面ではなく個々の「駒」を計算単位（エージェント）とする探索なし将棋 AI 「こころ将棋（KokoroPolicy）」の設計・学習・評価をまとめたものである。本 AI は盤上・駒台の全 40 駒をトークンとする共有 Transformer を中核とし、各駒が持つ 6 つの欲求と駒種ごとの性格の内積として指し手のスコアを構成する。これにより、強さを担う素のニューラル方策と、指し手を駒の動機として説明する解釈可能な構造とを分離して両立させる。約 500 万パラメータのモデルを floodgate 棋譜 155,992 局（約 2,240 万局面）で系列蒸留し、さらに自己対戦 PPO と文化リーグによる学習を行った。推論では先読みを用いず、1 度の計算で全駒の主張をまとめて指し手を決定する。外部の強豪評価関数 Hao を探索 1 手に制限した基準を用いて棋力を評価した。本報告では、この入力表現・モデル構造・学習・推論・評価の全体像を述べる。

1 はじめに

一般的な将棋 AI は「盤面」を入力として指し手を決め、1 手あたり数万から数億局面を先読み（探索）する。本プロジェクトの目的は次の 2 点にある。(a) 探索を用いずに将棋を指せる程度に強くすること、(b) その指し手を駒ごとの動機として説明できることである。探索は棋力に寄与するが、「駒たちが議論して手を決める」という説明枠組みと噛み合わない。そこで本 AI は原則として先読みを行わず、局面を 1 度だけ計算して手を決める探索なし方策を採用 [1]（ただし推論時に限り、ルールベースの 1 手詰め検査のみを例外として併用する。これは探索ではなく着手前の安全弁である）。

設計の中核原則は、感情・性格・絆といった「面白さ」の機能をすべて**初期値 0 の加算**として組み込むことである。学習前は加算項が 0 なので、これらが無効化すると素の将棋 AI と数値的に完全に一致する。この原則により、解釈構造を足しても棋力が即座に劣化することはない。

2 入力表現とベクトルの次元

局面を数値化する処理をトークン化と呼ぶ。本 AI は盤の 81 マスではなく、初期配置における先手 20 枚+後手 20 枚の**全 40 駒**をトークンとする（表 1）。駒は取られても消えず、位置が駒台（81 または 82）に移り所有者が反転する。これによりトークン数が常に 40 に固定され、計算グラフの形が対局を通じて不変になる。

各駒トークンは駒種・位置・成/所有フラグの埋め込みに、個性性格 $\theta^{ind} \in \mathbb{R}^{16}$ と感情 $m \in \mathbb{R}^{32}$ の射影を加えた $d_{\text{model}} = 256$ 次元ベクトル $x_i^{(0)}$ として表現される：

$$x_i^{(0)} = E_{sp}[c(i)] + E_{pos}[p(i)] + E_{flag}[\cdot] + W_{ind}\theta_i^{ind} + W_m m_i^{(t)}.$$

位置は 0-82 の番号にすぎず、マスの隣接や飛角香の利きの直線といった将棋の幾何はこの数値に含まれない。AI はそれを学習から再構成している。

3 モデルアーキテクチャ

3.1 全体のデータフローと次元

入力から指し手までの流れと各段のベクトル次元を図 1 に示す。

表 1: 駒トークンを構成する整数列と補助表 ($N = 40$)

名称	形	値域	意味
species (駒種)	40	0-13	歩から龍までの 14 種
position (位置)	40	0-82	0-80=盤, 81/82=先後の駒台
owner (所有)	40	0/1	先手/後手
promoted (成)	40	0/1	成っているか
effect (利き)	40×40	0/1/2	無関係/取れる/守っている
relation (絆)	40×40	[0, 1]	守り合いの EMA 蓄積
legal (合法手)	$40 \times 81 \times 2$	真偽	指せる手か




図 1: 入力から指し手・形勢に至るデータフローと各段のベクトル次元

表 2: 欲求 6 軸と自動生成される教師ラベル ($k = 4$ 手先読み)

軸	意味	教師ラベル
生存	取られずに残るか	4 手後も盤上なら 1
攻撃	捕獲・王手に関与	4 手以内に取り/王手で 1
成り	4 手以内に成るか	実際に成れば 1
守備	味方 (玉は 2 倍) への利き	守る味方数を正規化
前進	敵陣へ接近するか	4 手後に前進で 1
再登場	持ち駒が打たれるか	4 手以内に打てば 1

3.2 共有 trunk と注意バイアス

trunk は 40 駒トークンを受け、駒同士の関係を読み込む本体で、同一形状の Transformer 層を 6 段直列に並べる (Pre-LN, 残差接続, 各層 FFN 内部次元 1024)。注意計算には将棋のルールに由来する情報を加算バイアスとして与える:

$$e_{ij} = \frac{(x_i W_Q)(x_j W_K)^\top}{\sqrt{32}} + B_{\text{利き}}[\text{effect}_{ij}][h] + w_r[h] r_{ij}.$$

除数 $\sqrt{32}$ はヘッドあたり次元 $256/8 = 32$ に対応する。利きバイアスは $3 \times 8 = 24$ 個、絆重みは 8 個の計 32 個のみで駒の関係を表現する。いずれも初期値は 0 で、学習を通じて「攻撃を見るヘッド」「守りを見るヘッド」などへ自発的に分化する [4]。

3.3 欲求・性格ヘッドと方策

本 AI の解釈可能性は 6 軸の欲求に立脚する。各軸の定義と、棋譜から先読み幅 $k = 4$ 手で自動生成する教師ラベルを表 2 に示す。

trunk 出力 h_i に手の情報 (移動先の位置埋め込みと成りフラグ) を連結した手特徴 $u_{i,a} = [h_i \parallel E_{\text{pos}}[\text{dst}(a)] \parallel \rho(a)] \in \mathbb{R}^{321}$ から欲求 $d_i(a) \in [0, 1]^6$ と自由項 $g_i(a) \in \mathbb{R}$ を出し、駒 i が手 a を指したい度合いを

$$s_i(a) = \langle w_i, d_i(a) \rangle + g_i(a)$$

で構成する。性格重み w_i は softplus により必ず正で、これが解釈可能性の要である (「生存を重く見る駒」のように読める)。自由項 g には L2 罰則 λ_g がかかり、罰則下でも大きい g を持つ手は欲求に反した大局的判断=捨て駒に相当する。最終的に全 40 駒 $\times$ 81 マス $\times$ 成否の 6480 通りを単一の温度付き softmax にかける (式 (1)) ことで、駒同士が確率を奪い合う「調停」が表現される。

$$\pi(a | s) = \frac{\exp(s_{i,a}/\tau)}{\sum_j \sum_{a' \in \mathcal{A}_j} \exp(s_{j,a'}/\tau)}, \quad a \in \mathcal{A}_i. \quad (1)$$

非合法手は softmax の前に -10^9 へ置換して分母から実質的に除く。会議ループは新たな層を作らず、trunk の第 5・6 層を提案 8 トークンとともに R 回再適用して主張を更新する。 $R = 2$ で実効的な深さは $6 + 2R = 10$ 層に相当し、学習し直さずに R を変更できる。

3.4 パラメータ配分と設計選定

本モデルは合計 5,000,823 パラメータを持つ (この合計に外付けの感情 GRU 4,128 は含めない)。配分を表 3 に示す。棋力を担う trunk が 95.5% を占め、「こころ」に関わる部分 (性格 518 + 感情 GRU 4,128 + 絆 8) は全体の約 0.09% にすぎない。

表 3: 部品別のパラメータ配分 (mood/reactions/council 有効時)

部品	パラメータ	割合
trunk (Transformer 6 層)	4,774,176	95.47%
proposal_embed (会議の提案埋込)	108,032	2.16%
mixing (価値の単調混合)	76,586	1.53%
desire_head (欲求 6 軸)	20,838	0.42%
free_term_head (自由項)	20,673	0.41%
personality (駒種性格)	518	0.01%
合計 (GRU 除く)	5,000,823	100%
(外付け) 感情 GRU	4,128	—

3.5 アーキテクチャ選定の方針と新規性

選定方針は「新規アルゴリズムを発明せず、実績ある手法の駒粒度への適用に新規性を置く」ことである。trunk とトークン化は Chessformer/Lc0 系 [4], 蒸留は dlshogi 流の教師あり学習 [8], 自己対戦は MAPPO[6], 価値の単調 mixing は QMIX[5], 会議は Universal Transformer の反復適用 [7] に基づく。本 AI の新規性は, (a) 完全情報ターン制ゲームへの駒粒度マルチエージェント適用, (b) 「持ち駒＝駒の転生」という将棋固有問題の扱い, (c) 構造的な解釈可能性と棋力のトレードオフの定量化, の 3 点にある。

3.6 手をまたぐ状態

局面から定まる計算とは別に, 前の手から引き継ぐ状態が 3 つある。感情 m_i は駒ごと 32 次元で, 自分の移動・捕獲・被捕獲・成り・味方喪失・敵喪失・被王手・自玉王手・駒得増減の 9 種のイベントを入力に GRU で 1 手ごと更新する (全駒共有で 4,128 パラメータ)。絆 r_{ij} はペアごと 1 値で $r \leftarrow 0.9r + 0.1 \times$ (今の守り関係) と更新する。個性性格 θ_i^{ind} は駒ごと 16 次元で, SQLite に保存して対局を跨いで蓄積する。

4 学習方法

4.1 データセットと前処理

学習データはコンピュータ将棋対局サーバ **floodgate** の公開棋譜 (CSA 形式) である。2008–2026 年の 19 年分 1,883,113 局を取得し, 両者レート 3000 以上・手数 50–400・平手初期局面から・中断や不正終局でない, という条件で採否判定する。採用後の規模は **155,992 局 (約 2,240 万局面, 226 シャード, 11GB)** である。シャードは局の切れ目でのみ区切り, 感情 GRU が 1 局の流れを学習できるようにする。分割は局単位で行い, 検証用に別の 32 局を確保して過学習を監視する。欲求 6 軸の教師は表 2 のとおり棋譜から自動生成し, 人手のラベル付けを要しない。

4.2 統一損失と 3 段階の学習

全フェーズ共通の骨格として次の統一損失を用いる：

$$L = L_{\text{policy}} + c_1 L_{\text{value}} + c_2 L_{\text{desire}} + \lambda_g L_g - c_3 H(\pi), \quad (2)$$

係数は $c_1=1.0$, $c_2=0.5$, $\lambda_g=0.01$, $c_3=0.01$ である。 L_{policy} のみがフェーズで入れ替わる。学習は次の 3 段階からなり, 各フェーズが動かすパラメータ規模を表 4 に示す。

表 4: 各学習フェーズが動かすパラメータ規模

フェーズ	更新対象	規模
系列蒸留	モデル全体 (GRU 含む)	約 500 万
自己対戦 PPO	モデル全体 (GRU 凍結)	約 500 万
文化リーグ	駒種性格 + 温度 $\cdot \lambda_g$	224 (+ハイパラ 2)

1. **系列蒸留 (主軸)** : floodgate 棋譜 155,992 局を 3 周 (3 エポック, 1 エポック約 13 時間)。TBPTT 16 手, AdamW, 学習率 2×10^{-4} , バッチ 24 局。学習時の温度は $\tau=1$ である。
2. **自己対戦 PPO** : 蒸留モデルを起点に 9,200 反復 (GAE $\gamma=1$, $\lambda=0.95$, クリップ $\epsilon=0.2$) [6]。感情 GRU は既定で凍結し観測として扱う。
3. **文化リーグ** : 駒種性格 θ^{sp} (14 種 $\times$ 16 次元 = 224 個, 学習可能) と温度 $\cdot \lambda_g$ (ハイパーパラメータ 2 個) のみを進化させる PBT。trunk とヘッドは全文化で共有する。

5 推論フロー

推論は「局面を入れたら手が出る」単純な関数ではなく、対局の初手から終局まで状態 (感情 m , 絆 R , 駒追跡器) を持ち回る。1 手の手続きは次の通りである: (1) 盤を進めて駒 ID を追跡しイベント 9 種を計算, (2) $m \leftarrow \text{GRU}$, R を更新し利き行列を再計算, (3) 1 手詰めを検査し, あればそれを指す (安全弁), (4) モデルを **1 回** 計算して 6480 通りのスコアを得る (非合法手は -10^9), (5) 会議で上位 8 手を提案トークン化し第 5–6 層で再スコアリング, (6) 評価時は $\tau=0$ の argmax で手を選び, cshogi の手へ変換する。なお温度は文脈で使い分け, 学習時 $\tau=1$, 評価時 $\tau=0$ (argmax) を既定とする (設計文書では対局時 $\tau \approx 0.1$ も想定)。計算量は 1 手あたりモデル計算 1 回, 実効深さ $6 + 2R$ 層で, 100 局 (平均 130 手) を CPU 2 スレッドで 40–55 秒である。持ち駒を含む途中局面からは駒 ID を復元できないため, 平手初期局面から手順を与える必要がある。

6 評価と結果

6.1 外部基準に対する棋力

2026 年 9 月 19 日に, 強豪評価関数 Háo (やねうら王 + NNUE) [9] を探索 1 手 (go depth 1) に制限した固定基準を構築した。floodgate 由来の 500 種の序盤を配って同一棋譜の量産を防ぎ, 先後各 50 局の計 100 局を戦わせ, 同一序盤・同一手番の対を単位とする対応あり符号検定で比較する。勝率は勝ち 1・引き分け 0.5・負け 0 で定義する。主要な結果を表 5 に示す。主系列モデルの中では現行の ppo2 が最強で勝率 **0.230** (標準誤差 ≈ 0.042) である。

6.2 解釈性のアブレーション

感情 (A)・関係 (C)・会議 (D) の有無を組み合わせた蒸留一致率と欲求説明率を表 6 に示す (単一 seed・同一局面での測定であり, 差の解釈には注意を要する)。一致率は 0.332–0.354 の狭い範囲に収まり, 解釈構造の付与による棋力への影響は小さい。これとは別の λ_g 掃引実験 (図 2) では, 欲求説明率を 19% から 99.6% へ引き上げても一致率の低下はわずか 1.09 ポイントであり, **解釈性はほぼ無償で得られる**ことを示す。

表 5: 対 Háo (depth 1) 勝率 (100 局, SE ≈ 0.04)

モデル	由来	勝率
teach2023_50k	エンジン教師蒸留 5 万局	0.245
ppo2	蒸留 3ep + PPO 9,200 反復 (主系列で最強)	0.230
phase37_e3	蒸留 3 エポック (系列の起点)	0.220
phase37_e4	蒸留 4 エポック	0.200
phase37_e2	蒸留 2 エポック	0.110
E2b culture1	文化リーグ	0.100
e4c.iter100	感情 GRU 解凍 (lr 10^{-4})	0.050
b_fix_R6	$R=2$ 学習 $\cdot R=6$ 推論	0.000

表 6: 機能 ON/OFF のアブレーション (A: 感情, C: 関係, D: 会議)

構成	一致率	欲求説明率
none	0.342	0.777
a	0.349	0.759
c	0.351	0.780
d	0.332	0.793
ac	0.354	0.756
ad	0.344	0.698
cd	0.338	0.805
acd	0.344	0.691




図 2: 解釈性 (欲求説明率) と棋力 (一致率) のトレードオフ (λ_g 掃引)

表 7: 強化策と外部勝率の変化 (2026 年 9 月)

施策	外部勝率の変化	判断
自己対戦 PPO 9,200 反復	+0.01	追加投資を停止
文化リーグ	-0.07 ~ -0.13	強さ目的では停止
感情 GRU 解凍	-0.18 (用量依存)	停止
エンジン教師蒸留	± 0 ($p=0.84$)	棚上げ
会議 $R=1 \sim 6$	横ばい	頑健性として採用
trunk 4 エポック目	± 0 ($p=0.88$)	停止




図 3: 自己対戦 PPO の世代別勝率 (直前世代比): 内部では改善するが最後に頭打ち

6.3 効かなかった強化策

2026 年 9 月 19 日以降に試した 6 件の強化策は、外部基準では有意な改善を確認できなかった (表 7)。自己対戦 PPO は自分の過去世代には勝ち越すが (図 3)、外部基準では +0.01 に留まる。文化リーグは進化対象が性格 224 個のみのため一貫して弱くなり、感情 GRU の解凍は動かすほど棋力が単調に低下した。100 局規模では検出力に限界があるため、これらは「効果なし」の証明ではなく「有意な効果を検出できなかった」と解釈すべきである。

7 考察と今後の展望

追加の蒸留エポックでは、学習データ上の一致率は各エポックで上昇し続ける (45.4 → 47.3%) 一方、検証データ上ではほぼ停止し (40.9 → 41.5%)、両者の差が広がる。これは典型的な過学習の兆候であり、現状の律速がモデル容量ではなく学習データ量にある可能性を示唆する。したがってモデルの拡大は優先度が低く、まず取り組むべきはデータ増強である。実際に floodgate の取得年を拡大し (188 万局)、レートに応じた線形重み付け [3] でシャードを再生成している。

今後の主要な方策は次の 3 点である。(a) 「駒の一生」を教師にする損失の導入。現在どの損失にも使われていない駒別価値 V_i へ、棋譜から無償で得られる将来情報 (成る・取られる・生き残る) を与える。(b) 利きバイアスを幾何 (同一筋・段・斜め・距離・遮り) を表す形へ拡張する [4]。(c) 価値損失を WDL + 残り手数予測へ変更し、導出可能な特徴を入力に加える [2] (チェスでは合計 +180 Elo)。加えて、会議ループの停止則を適応化する余地があり (PonderNet[10])、探索模倣後の事前分布誘導探索 [11] や、会議を入札均衡として定式化する固定点ネットワーク [12] も

長期的な検討対象である。これらは、探索なし将棋 AI において「表現と損失がアーキテクチャより効く」という知見に沿った改良である。

参考文献

- [1] A. Ruoss *et al.*, “Grandmaster-Level Chess Without Search,” arXiv:2402.04494, 2024.
- [2] J. Czech *et al.*, “Representation Matters for Mastering Chess,” arXiv:2304.14918, ECAI 2024.
- [3] Y. Li and X. Jiang, “Tracking vs. Deciding: The Dual-Capability Bottleneck in Searchless Chess Transformers,” arXiv:2603.29761, 2026.
- [4] Anonymous, “Chessformer: A Unified Architecture for Chess Modeling,” arXiv:2605.19091, ICLR 2026.
- [5] T. Rashid *et al.*, “QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning,” ICML 2018.
- [6] C. Yu *et al.*, “The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games (MAPPO),” NeurIPS 2022.
- [7] M. Dehghani *et al.*, “Universal Transformers,” ICLR 2019.
- [8] 山岡 忠夫, “ディープラーニングを用いた将棋 AI dlshogi の開発,” 2020.
- [9] やねうらお, “やねうら王 (USI 将棋エンジン),” <https://github.com/yaneurao/YaneuraOu>.
- [10] A. Banino *et al.*, “PonderNet: Learning to Ponder,” arXiv:2107.05407, 2021.
- [11] Miłosz *et al.*, “Beyond Search-Imitation: Prior-Directed Exploration for Searchless Chess,” arXiv:2608.27757, 2026.
- [12] H. Heaton *et al.*, “Learn to Predict Equilibria via Fixed Point Networks,” arXiv:2106.00906, 2021.